

FICHE TECHNIQUE

Cette fiche contient les différents modèles et Dataset utilisé dans les travaux réalisés pour la détection de la toxicité dans les vidéos.

I. Modèle 1 : Classification de donnée textuelle pour la détection de toxicité

Dans cette partie il consiste à faire la retranscription d'une vidéo et la détection du texte OCR contenu dans une vidéo, ensuite classé le texte ; toxique ou sain.

1) Ensemble de donnée utilisées

- Toxicity-french-unsample

Ensemble de donnée partagée par le gouvernement français contenant du texte avec des gros mots et des insultes et du texte correcte [Lien dataset](#)

- hatecheck_case_final_french

Ensemble de donnée contenant des propos homophobes raciste misogyne et bien d'autre, pour la mise en place du modèle de classification nous avons transformer toutes ces propos discriminants comme toxique [Lien dataset](#)

- Jigsaw Multilingual Toxic Comment

Ce dataset contient des milliers de ligne de texte de plusieurs langues utiliser pour un challenge de classification de toxicité.

Pour la mise en place de mon modèle j'ai utilisé ces trois ensemble de donnée enfin de formé un seul ensemble de donnée avec :

Nombre de document : 297 562

Nombre de caractéristique : 3 (index,texte,target)

Prétraitement effectué

- Suppression ponctuation
- Mise en minuscule
- Correction des erreur orthographique
- Transformation des mots en lemma
- Vectorisation (TF-IDF)

Après prétraitement division du dataset en 3 partie

Train 70% du jeu de donnée

Val 20 % et Test 10%

2) Modèle et Evaluation


KNN

précision=0.96

classification report

-----Classification report-----				
	precision	recall	f1-score	support
0	0.97	0.96	0.96	5073
1	0.96	0.97	0.96	4927
accuracy			0.96	10000
macro avg	0.96	0.96	0.96	10000
weighted avg	0.96	0.96	0.96	10000

Matrice de confusion





ANN

Le deuxième modèle est une architecture de réseau de neurone avec des couches Dense

Architecture :

```
model1=Sequential([  
    Dense(64,activation='sigmoid'),  
    Dropout(0.1),  
    Dense(2,activation='softmax')  
])
```


Graphe entrainement



Loss=0.065

Accuracy=0.98

Matrice de confusion



RandomForest


Un Modèle de forêt aléatoire avec 100 estimateur

Précision : 0.77

Classification report

-----Classification report-----					
	precision	recall	f1-score	support	
0	0.75	0.88	0.81	1641	
1	0.81	0.63	0.71	1287	
accuracy			0.77	2928	
macro avg	0.78	0.76	0.76	2928	
weighted avg	0.78	0.77	0.77	2928	

Matrice de confusion



MultimodalNb (Naives Bayesient)

précision : 0.785

Classification Report


```

-----Classification report-----
              precision    recall  f1-score   support

     0       0.78         0.86         0.82         1641
     1       0.79         0.69         0.74         1287

 accuracy          0.79
 macro avg         0.79         0.78         0.78         2928
 weighted avg      0.79         0.79         0.78         2928
  
```

Matrice de confusion



3) Conclusion

Après ces travaux réalisés pour la détection de la toxicité à partir du texte, nous avons utilisé le modèle construit avec les réseaux d'architecture (ANN). Ce modèle a les meilleures performances et marche assez bien sur du texte court et également sur un texte long

II. EVENEMENT II : DETECTION DE LA TOXICITE DANS LA FREQUENCE SONORE

Description

Dans cette partie il est question de mettre en place un modèle machine learning capable de détecter de la toxicité à partir de la voix d'une vidéo en se basant sur des faits comme : le ton employé, les cris, le nombre d'interlocuteur à la fois, et bien d'autres

1) Ensemble de données

Pour cette partie nous avons utilisé principalement deux sources de données qui sont :

Common Voice

C'est un projet Open source mis en place par Mozilla dans lequel nous avons plusieurs contributeurs, Un dataset multi-langage utilisé dans de nombreux travaux de reconnaissance de la parole [Lien](#)

Youtube

Dans les travaux de reconnaissance de la voix Youtube est une plateforme idéale sur laquelle on pourrait collecter des données. Pour nos travaux nous avons recherché des vidéos qui peuvent être jugées comme toxiques ensuite avons extrait les audios et découpé ces audios en des fichiers de 5s pour que les données soient conformes avec celles collectées dans Common Voice

Synthèse

Après ce processus nous avons obtenu un ensemble de données d'audio qui contient au total : **39514**

Distribution des données

- Toxic:1 => 20986


- Saint:0 => 18528

Prétraitement

Pour construire le modèle de classification de fichier audio

il faut appliquer quelques techniques de prétraitement sur les données audio

- Transformation de l'audio en fréquences sonores
- suppression du silence de début et de fin
- Déterminer les caractéristique spectraux mfcc
- Normalisation du mfcc en fonction des moyennes et des écart-type
- Redimensionner les données afin qu'elles ait la même taille pour chaque fichier



2) Modèle et évaluation

Modèle 1 : CNN+ANN

Architecture

```
Model: "sequential"
```


Layer (type)	Output Shape	Param #
normalization (Normalization)	(None, 13, 600, 1)	3
conv2d (Conv2D)	(None, 13, 600, 32)	832
max_pooling2d (MaxPooling2D)	(None, 5, 200, 32)	0
conv2d_1 (Conv2D)	(None, 5, 200, 64)	8256
max_pooling2d_1 (MaxPooling2D)	(None, 3, 100, 64)	0
conv2d_2 (Conv2D)	(None, 3, 100, 128)	73856
max_pooling2d_2 (MaxPooling2D)	(None, 2, 50, 128)	0
global_average_pooling2d (GlobalAveragePooling2D)	(None, 128)	0
dense (Dense)	(None, 64)	8256
dropout (Dropout)	(None, 64)	0
dense_1 (Dense)	(None, 1)	65

```
=====
Total params: 91268 (356.52 KB)
Trainable params: 91265 (356.50 KB)
Non-trainable params: 3 (16.00 Byte)
```



Evaluation

- Loss :0.038
- Accuracy : 0.98
- AUC : 0.99
- Precision : 0.98
- Rappel : 0.99

Matrice Confusion



ROC AUC



Classification Report

```
17/61 [=====>.....] - ETA: 2s
61/61 [=====] - 3s 45ms/step
      precision    recall  f1-score   support

     0       0.99       0.98       0.98       3664
     1       0.98       0.99       0.99       4144

   accuracy       0.99       0.99       0.99       7808
  macro avg       0.99       0.99       0.99       7808
 weighted avg       0.99       0.99       0.99       7808
```

Model 2 : ANN


Le deuxième modèle à une architecture composée uniquement de couche ANN

Objectif est de voir s'il est possible d'obtenir des résultats plus concluant que l'architecture CNN+ANN. Nous avons deux couche de ANN (Dense) qui sont chacune couplée d'une couche Dropout pour régulariser le modèle et éviter le problème de l'exposition du gradient car on utilise RELU comme activation. La première couche à 64 Neurones et la deuxième à 32 Neurones.

Evaluation du modèle ANN


- Perte : 0.11
- Accuracy : 0.94
- AUC :0.99
- Précision :0.98
- Rappel :0.93

Matrice de convolution



Le modèle à fait 91 Erreurs pour la classe Saint 0 sur 1466 et 50 sur la classe Toxique :1 sur 1350 au total

Courbe AUC ROC :0.95



Nous obtenons une aire du ROC qui vaut 0.95 proche de 1 ce qui est un bon resultats

Classification report

22/22 [=====] - 0s 2ms/step				
	precision	recall	f1-score	support
0	0.94	0.96	0.95	1425
1	0.96	0.93	0.95	1391
accuracy			0.95	2816
macro avg	0.95	0.95	0.95	2816
weighted avg	0.95	0.95	0.95	2816

Modèle 3 : LSTM


Le troisième modèle est une architecture LSTM, les couches LSTM ont une mémoire à long terme il serait donc intéressant d'essayer une architecture avec un modèle LSTM afin de savoir si le modèle est capable de capturer sémantiquement des informations séquentielles

```
model3=Sequential([
    Input(shape=INPUT_SHAPE),
    tf.keras.layers.Normalization(),
    tf.keras.layers.Reshape(target_shape=(13,600)),
    tf.keras.layers.LSTM(64,return_sequences=False,activation='tanh'),
    tf.keras.layers.Flatten(),
    Dense(64,activation='relu'),
    Dropout(0.3),
    Dense(32,activation='relu'),
    Dropout(0.2),
    Dense(1,activation='sigmoid')
])
```


Evaluation

- Perte : 0.094
- Accuracy : 0.97
- AUC : 0.99
- Précision : 0.96
- Rappel : 0.97

Matrice de convolution



AUC ROC courbe




Modèle 4 : CNN+(LSTM)+ANN

Ce modèle est une architecture composée de plusieurs types de Neurones

Evaluation du modèle

- Perte : 0.075
- Accuracy : 0.97
- AUC :0.99
- Précision :0.97
- Rappel :0.97

Matrice de Convolution



*Le modèle à fait 36 Erreurs pour la classe
Saint 0 sur 1466 et 44 sur la classe
Toxique :1 sur 1350 au total*

AUC ROC courbe


Modèle 5 : CNN+Bi(LSTM)+ANN

Bidirectional_LSTM : La couche Bidirectional LSTM (Long Short-Term Memory) est une variante de la couche LSTM qui permet de traiter les données d'une séquence dans les deux directions, vers l'avant et vers l'arrière, pour chaque séquence d'entrée. Cela permet d'encoder plus d'informations contextuelles, ce qui peut être particulièrement utile dans les tâches où le contexte de la séquence entière est important pour chaque élément de la séquence


Evaluation

- Perte : 0.1
- Accuracy : 0.967
- AUC :0.99
- Précision :0.97
- Rappel :0.961

Matrice de Confusion



AUC ROC curve



3) Etude comparatives des modèles

Métrique	Modèle 1	Modèle 2	Modèle 3	Modèle 4	Modèle 5
Perte	0.045	0.087	0.094	0.101	0.10
Accuracy	0.9843	0.97	0.970	0.966	0.967
AUC	0.98	0.996	0.992	0.993	0.99
Précision	0.988	0.986	0.967	0.965	0.974
Rappel	0.998	0.95	0.973	0.967	0.961
F1-Score	0.98	0.97	0.97	0.97	0.97
ROC Aire	0.98	0.97	0.97	0.97	0.97

⇒ Après cette Analyse on constate que le premier modèle (CNN+ANN) présente les meilleurs résultats pour ces travaux réalisés sur la détection de la toxicité dans la voix à travers différents phénomène comme le thon, les bruits autour ,les moqueries et des disputes.

III. MULTIMODAL CLASSIFIER TOXICITY

Description

En machine learning un modèle multimodal est un modèle pouvant être entraîné sur plusieurs modalités (donnée). L'objectif est de combiner plusieurs facteurs afin d'avoir une représentation parfaite de l'information comme le fait les êtres humains qui se base sur tout ses sens (5) pour prendre une décision.

Contexte : Nous avons mis en place ce modèle pour permettre de détecter de la toxicité (des propos sujets comme nuisible) dans une vidéo, Dans un premier temps nous avons mis un modèle qui se base sur le texte qui représente la vidéo pour la détection de la toxicité ensuite nous avons implémenté un modèle capable de détecter de la toxicité dans les fréquences sonores d'un fichier audio, Dans cette partie du travail nous allons mettre en place un modèle qui se base simultanément sur le texte et la fréquence sonore pour faire la prédiction.

Base de donnée

Comme source de donnée pour la mise en place du modèle nous avons utiliser plusieurs sources de données

Coomon Voice : Une collection de donnée de fichier audio avec la retranscription de chaque audio, c'est une base de donnée open source mise en place par Mozilla, par la suite nous avons utiliser des vidéos Youtube et avons découper ces fichiers en des séquences de 5s. Après le découpage de ces vidéos nous avons obtenu au total un jeu de donnée de 26640 exemplaire pour notre base d'entraînement distribué comme suite : Toxiques 14013 et 12627 Saint

Prétraitement

Texte : pour les données textuelles nous avons effectué les étapes de prétraitement suivantes :

- La suppression de la ponctuation
- Mise en minuscule
- Suppression des mots vides
- Lemmatisation des mots
- Et la vectorisation avec la technique du TfIdf (très efficace dans les cas où la présence d'une expression peut changer la signification d'une phrase


Audio : pour les données audios nous avons effectué les étapes suivantes :

- Suppression du silence de début
- Extraction des caractéristiques mfcc du fichier audio à l'aide de librosa
- La normalisation du tableau de fréquences
- Redimensionnement de chaque tableau de fréquence (13,224,1)



Architecture du modèle de classification

Dans cette partie nous avons utilisé tensorflow pour mettre en place un modèle un modèle de classification binaire entraîné sur deux types de données, des données Textuelles et des données audios.

Texte Input



Audio Input



Evaluation du modèle

Train 70% -> 70% pour entrainer le modèle

Val 20% -> 20% pour la validation du modèle


Test 10% -> 10% pour les tests (évaluation du modèle)

Le modèle a été entraîné sur 10 époques avec « adam » comme optimiseur, binary_crossentropy comme fonction de perte, les métriques d'évaluation suivantes : accuracy, auc, precision, et rappel


Nous avons obtenu les valeurs suivantes

- Accuracy= 0.986
- Perte =0.03
- Précision= 0.98
- Recall=0.99
- F1-score=0.99
- Area AUC= 0.99

Courbe d'entraînement



Matrice Confusion



Pipeline d'utilisation du modèle

